

1 Prvi sloj i njegove parcijalne derivacije

Ovdje su izvodi svih parcijalnih derivacija izlaza prvog sloja po parametrima. To će nam trebati kasnije kada ćemo izvoditi učenje svakog od parametara.

$$\begin{aligned} A_i &= \frac{1}{1 + e^{b_i(x-a_i)}} \\ \frac{\partial A_i}{\partial a_i} &= \frac{1}{(1 + e^{b_i(x-a_i)})^2} e^{b_i(x-a_i)} b_i = A_i^2 \left(\frac{1}{A_i} - 1 \right) b_i = A_i(1 - A_i)b_i \\ \frac{\partial A_i}{\partial b_i} &= \frac{-1}{(1 + e^{b_i(x-a_i)})^2} e^{b_i(x-a_i)} (x - a_i) = -A_i^2 \left(\frac{1}{A_i} - 1 \right) (x - a_i) = -A_i(1 - A_i)(x - a_i) \end{aligned}$$

$$\begin{aligned} B_i &= \frac{1}{1 + e^{d_i(y-c_i)}} \\ \frac{\partial B_i}{\partial c_i} &= \frac{1}{(1 + e^{d_i(y-c_i)})^2} e^{d_i(y-c_i)} d_i = B_i^2 \left(\frac{1}{B_i} - 1 \right) d_i = B_i(1 - B_i)d_i \\ \frac{\partial B_i}{\partial d_i} &= \frac{-1}{(1 + e^{d_i(y-c_i)})^2} e^{d_i(y-c_i)} (y - c_i) = -B_i^2 \left(\frac{1}{B_i} - 1 \right) (y - c_i) = -B_i(1 - B_i)(y - c_i) \end{aligned}$$

2 Drugi sloj i njegove parcijalne derivacije

$$w_i = A_i B_i$$

$$\frac{\partial w_i}{\partial A_i} = B_i \quad \frac{\partial w_i}{\partial B_i} = A_i$$

3 Treći sloj i njegove parcijalne derivacije

Ovaj sloj je normalizacijski sloj za kojeg neću posebno izvoditi derivacije, jer je lakše koristiti samo tu sumu kasnije u računu. Normalizacija svake od dobivenih težina provodi se na sljedeći način:

$$\bar{w}_i = \frac{w_i}{\sum_{j=1}^M w_j}$$

4 Četvrti i peti sloj i njihove parcijalne derivacije

$$f_i = p_i x + q_i y + r_i$$
$$f = \frac{\sum_{i=1}^M w_i f_i}{\sum_{i=1}^M w_i}$$

$$\frac{\partial f}{\partial f_i} = \frac{w_i}{\sum_{i=1}^M w_i} = \bar{w}_i \quad \frac{\partial f}{\partial w_i} = \frac{f_i \sum_{j=1}^M w_j - \sum_{j=1}^M f_j w_j}{(\sum_{j=1}^M w_j)^2} = \frac{\sum_{j=1}^M w_j (f_i - f_j)}{(\sum_{j=1}^M w_j)^2}$$

$$\frac{\partial f_i}{\partial p_i} = x \quad \frac{\partial f_i}{\partial q_i} = y \quad \frac{\partial f_i}{\partial r_i} = 1$$

5 Pogreška izlaza mreže

E je oznaka pogreške za 1 podatak pri čemu je y točna oznaka za podatak, a f je izlaz mreže za taj isti podatak.

$$E = \frac{1}{2}(y - f)^2$$

$$\frac{\partial E}{\partial f} = -(y - f)$$

6 Određivanje pravila učenja za svaki od parametara

Ideja je svaki od parametara (koji god da bio) mijenjati tako da se pomičemo u negativnom smjeru gradijenta pogreške E po tom parametru za dani podatak. Za proizvoljan parametar θ to bi glasilo:

$$\theta_{t+1} = \theta_t - \eta \frac{\partial E}{\partial \theta}$$

Budući da je gradijent (u ovom slučaju parcijalna derivacija) smjer najvećeg rasta funkcije, pomicanjem u negativnom smjeru gradijenta idemo u smjeru najvećeg pada ciljne funkcije (u ovom slučaju funkcije pogreške E) i to je ono

što nam odgovara jer želimo minimizirati pogrešku. Hiperparametar η je stopa učenja kojom reguliramo da koraci budu dovoljno maleni kako ne bi došlo do divergencije gradijentnog spusta.

Određimo sada parcijalne derivacije pogreške po svakom od parametara:

$$\begin{aligned}\frac{\partial E}{\partial a_i} &= \frac{\partial E}{\partial f} \frac{\partial f}{\partial w_i} \frac{\partial w_i}{\partial A_i} \frac{\partial A_i}{\partial a_i} & \frac{\partial E}{\partial p_i} &= \frac{\partial E}{\partial f} \frac{\partial f}{\partial f_i} \frac{\partial f_i}{\partial p_i} \\ \frac{\partial E}{\partial b_i} &= \frac{\partial E}{\partial f} \frac{\partial f}{\partial w_i} \frac{\partial w_i}{\partial A_i} \frac{\partial A_i}{\partial b_i} & \frac{\partial E}{\partial q_i} &= \frac{\partial E}{\partial f} \frac{\partial f}{\partial f_i} \frac{\partial f_i}{\partial q_i} \\ \frac{\partial E}{\partial c_i} &= \frac{\partial E}{\partial f} \frac{\partial f}{\partial w_i} \frac{\partial w_i}{\partial B_i} \frac{\partial B_i}{\partial c_i} & \frac{\partial E}{\partial r_i} &= \frac{\partial E}{\partial f} \frac{\partial f}{\partial f_i} \frac{\partial f_i}{\partial r_i} \\ \frac{\partial E}{\partial d_i} &= \frac{\partial E}{\partial f} \frac{\partial f}{\partial w_i} \frac{\partial w_i}{\partial B_i} \frac{\partial B_i}{\partial d_i}\end{aligned}$$

Uvrštavanjem prije dobivenih izraza u svaku od jednadžbi dobivamo:

$$\frac{\partial E}{\partial a_i} = -(y - f) \frac{\sum_{j=1}^M w_j (f_i - f_j)}{(\sum_{j=1}^M w_j)^2} B_i A_i (1 - A_i) b_i$$

$$\frac{\partial E}{\partial b_i} = -(y - f) \frac{\sum_{j=1}^M w_j (f_i - f_j)}{(\sum_{j=1}^M w_j)^2} B_i (-A_i) (1 - A_i) (x - a_i)$$

$$\frac{\partial E}{\partial c_i} = -(y - f) \frac{\sum_{j=1}^M w_j (f_i - f_j)}{(\sum_{j=1}^M w_j)^2} A_i B_i (1 - B_i) d_i$$

$$\frac{\partial E}{\partial d_i} = -(y - f) \frac{\sum_{j=1}^M w_j (f_i - f_j)}{(\sum_{j=1}^M w_j)^2} A_i (-B_i) (1 - B_i) (y - c_i)$$

$$\frac{\partial E}{\partial p_i} = -(y - f) \frac{w_i}{\sum_{j=1}^M w_j} x \quad \frac{\partial E}{\partial q_i} = -(y - f) \frac{w_i}{\sum_{j=1}^M w_j} y \quad \frac{\partial E}{\partial r_i} = -(y - f) \frac{w_i}{\sum_{j=1}^M w_j}$$

Prema pravilu učenja za proizvoljan parametar obnavljat ćemo vrijednosti svakog od parametara u algoritmu. Međutim javljaju se dvije inačice algoritma učenja: stohastička i grupna. Stohastička se inačica algoritma ponaša tako da




Abbildung 1: Ciljna funkcija

obnavlja parametre nakon svakog podatka koji prođe kroz mrežu, pa se tako u jednoj epohi parametri obnavljaju N puta gdje je N broj podataka za učenje. Grupa se pak inačica ponaša tako da uprosječuje gradijente po svim uzorcima za učenje i tako se parametri obnavljaju samo jednom u jednoj epohi učenja.

7 Ciljna funkcija

Ciljna funkcija glasi:

$$((x - 1)^2 + (y + 2)^2 - 5xy + 3) * \cos^2\left(\frac{x}{5}\right)$$

i njen izgled je prikazan na slici 1

8 Prikaz rada mreže za različiti broj pravila




Abbildung 2: Izgled naučene funkcije za samo jedno pravilo.

Figure 1




Abbildung 3: Ploha pogreške za samo jedno pravilo.




Abbildung 4: Izgled naučene funkcije za dva pravila.




Abbildung 5: Ploha pogreške za dva pravila.




Abbildung 6: Izgled naučene funkcije za osam pravila.




Abbildung 7: Ploha pogreške za osam pravila.

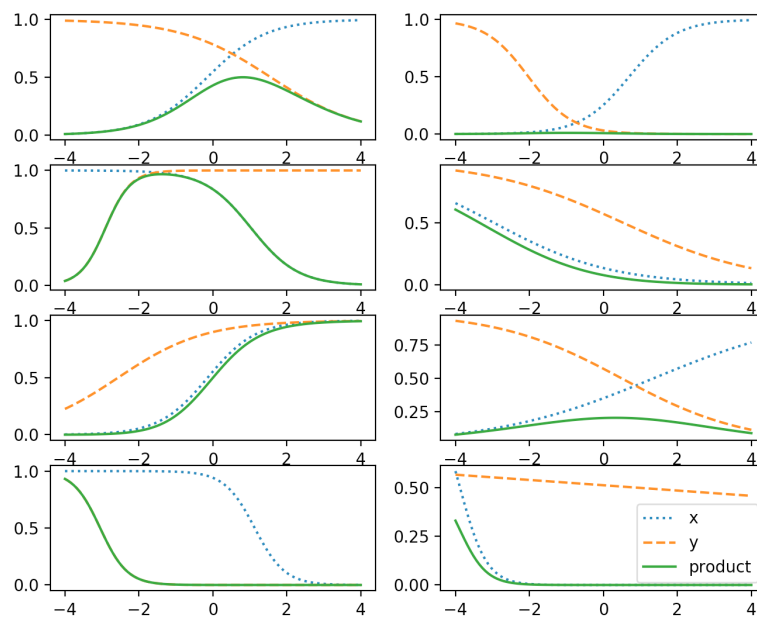


Abbildung 8: Naučene funkcije pripadnosti za 8 pravila.